GentleVanguard

ADOPCIÓN INTERNA DE IA - STACK GOBERNADO

Una capa de orquestación para la IA de su empresa

Un stack local-first que convierte asistentes de IA en capacidad gobernada: con roles definidos, presupuesto de tokens, trazabilidad y auditoría.

Local first | Trazable | Portable

Stack v4.3.0 - Noviembre 2026



QUIÉN LO CONSTRUYE

Quien conoce la IA aplicada en empresas grandes ya lo hizo antes

Emmanuel Ortiz Gutierrez: arquitecto de software, ingeniero de integración de IA y fundador de GentleVanguard. Más de 15 años construyendo y analizando sistemas para empresas: arquitectura de software e integración de IA en DIRECTV Latin America, consultoría técnica en GlobalLogic y Oracle, y análisis, QA y coordinación de equipos de desarrollo.

DIRECTV

Latin America

Arquitectura de software e integración de IA

GlobalLogic

Oracle

Consultoría técnica para clientes enterprise

UNSJ

Sistemas de Información

Licenciatura en Sistemas de Información

El stack no es un chatbot: es la capa que lo gobierna

Cada capa resuelve una capa de problemas y deja registro de lo que hizo.

Un roster de agentes

21 agentes con modelo, permisos, pasos y presupuesto asignados.

Capacidades

250 skills reutilizables que se invocan por contexto, no por código.

Evidencia

Sesiones, trazas, eventos y auditoría encadenada por hash.

Controles

Políticas fail-closed, escaneo de secretos y trazabilidad de permisos.

Herramientas	CLI, IDEs y superficies de producto
Agentes	Perfiles especializados por runtime
Orquestación	Contexto, ruteo y pasos
Conocimiento	Engram, CodeGraph y Graphify
Datos operativos	Nexus / SQLite, separado
Calidad y entrega	Gates, revisión y evidencia

Nueve capas, cada una con un límite explícito

La estructura es lo que permite auditar, reemplazar o extender una pieza sin romper el resto.

Superficies	Diez perfiles de herramienta auditados (OpenCode, Codex, ZCode, MiniMax Code, Claude Code, Antigravity, Cursor, Cline, Windsurf y VS Code) sobre el mismo workspace.
Orquestación	Enrutamiento de modelo y agente, escalado de pasos por complejidad y tabla de ruteo aprendible con 17 dominios y overrides.
Agentes	21 definiciones con permisos y límites de pasos; 27 roles mapeados y 30 bindings de modelo por área y criticalidad.
Capacidades	250 skills locales y 32 de OpenCode, con 28 críticas bajo contrato verificado en ejecución real.
Conocimiento	Engram (memoria), CodeGraph (índice incremental), graphify (grafo AST determinista) y Nexus (43 tablas, 22 migraciones, WAL).
Herramientas	Diez servidores MCP con acceso uniforme, incluidos dos externos bajo circuito con control de falla.
Infraestructura	Watchtower con 154 checks sobre 29 componentes, 6 modos de operación y autoheal.
Observabilidad	Dashboard con trazas reales, health API de 7 componentes, exportación OTLP y alertas configurables.
Aplicaciones	28 apps propias que operan sobre el stack y validan la arquitectura en producción.

ESCALA

No es un prototipo: es un sistema en uso sostenido

Cifras verificadas contra el repositorio en la versión 4.3.0.

786

Archivos TS en src/

Código propio del stack, con módulos por área

272

Archivos de test

Unit, e2e, integración, seguridad y skills

583

Scripts npm

Cada operación del stack es un comando auditable

154

Checks de salud

Sobre 29 componentes, con autoheal

CAPACIDADES

Lo que la empresa recibe al instalar el stack

Roles, no personas

27 roles mapeados con subagentes primarios y de respaldo, disparadores y skills. La IA deja de ser "la herramienta de Fulano" y pasa a ser un rol con estándar.

Costo bajo control

Presupuesto diario de 10 millones de tokens, 3 millones por sesión y 100 mil por agente, con enrutamiento por costo, latencia y carga.

Permisos explícitos

Permisos por agente, políticas fail-closed, gateway de seguridad MCP, escaneo de secretos y separación entre datos reconstruibles y no reconstruibles.

OPERACIÓN

Cómo se ejecuta una tarea de punta a punta

El loop no cambia entre un proyecto de una semana y uno de seis meses.

Pre-proceso

Cada turno inyecta contexto, skills y reglas antes de que el modelo responda.

>

Enrutamiento

El router elige modelo y agente según el dominio, la complejidad y el costo.

>

Ejecución

El agente trabaja con herramientas reales y deja traza de cada paso.

>

Verificación

Los gates y el revisor cierran el ciclo antes de declarar el trabajo terminado.

Lo que impide que esto sea un experimento sin control

30 quality gates

13 en pre-commit, 2 en commit-msg, 2 en post-commit, 3 en pre-push, 8 en CI, 1 de gobernanza y 1 de despliegue. 28 de 30 aplicados de forma estricta.

Escaneo de secretos

80 patrones con filtro de entropía opcional y redacción por defecto, integrado al hook y al watchtower. Tres escáneres independientes conviven.

Auditoría encadenada

Event sourcing con prevHash y hash SHA-256 por evento. Detecta mutación accidental o edición inconsistente del registro.

Trazabilidad de suministro

SBOM generado y validado, procedencia de artefactos y mapeo documentado contra OWASP Top 10 para agentes.

Observabilidad real

Dashboard sin datos simulados: métricas, trazas, alertas y feedback salen de la operación, no de una maqueta.

Respaldo y recuperación

Backup diario programado de la base con 14 copias retenidas, más simulacros de recuperación con RTO y RPO medidos.

Adoptar IA herramienta por herramienta, o con una capa de orquestación

Es la diferencia entre un contrato de software y una capacidad organizacional.

Stack gobernado

La capacidad queda en la empresa

- Un mismo estándar para todos los equipos, definido en el repositorio.
- Presupuesto, permisos y límites por rol, no por proveedor de herramienta.
- Evidencia de cada tarea: traza, eventos y auditoría encadenada.
- Conocimiento del proceso en la base de la empresa, no en la memoria de un chat.
- Continuidad: el stack se actualiza y se migra con versionado.
- Funciona con el proveedor de modelos que la empresa elija o con modelos locales.

Herramienta por herramienta

Cada equipo improvisa su propio camino

- Cada herramienta con sus propias reglas, sin estándar compartido.
- Costo invisible hasta que aparece la factura.
- Sin registro de qué hizo el modelo ni con qué datos.
- El conocimiento del proceso se pierde con cada conversación.
- Dependencia del proveedor: cambiar de herramienta es rehacer todo.
- Sin camino de actualización: cada versión nueva es un proyecto.

TOPOLOGÍA

Dónde vive cada parte, y por qué importa

La operación es local; la exposición es opcional y reversible.

Capa	Residencia	Razón de diseño
Orquestación y agentes	Local, en la máquina del equipo	El control del proceso no depende de un servicio externo
Base operacional (Nexus)	SQLite local en WAL	Consulta sin latencia de red y con respaldo programable
Memoria y conocimiento	Local, con sincronización opcional	El contexto organizativo no sale de la máquina por defecto
Modelos	Proveedor o local	Cadena de failover: proveedor, luego Ollama, luego LM Studio
Aplicaciones	Local o nube según el caso	Se exponen por URL cuando hace falta, sin cambiar la lógica
Auditoría y trazas	Archivos locales versionados	Se pueden archivar, enviar a un SIEM o retener según política

ECONOMÍA

El costo de la IA, medido y acotado

El router decide modelo por costo, latencia y carga. Los presupuestos cortan antes de que el gasto se convierta en sorpresa.

10M

Tokens por día

Presupuesto global con corte blando al 70 por ciento

3M

Tokens por sesión

Techo por sesión de trabajo

100k

Tokens por agente

Cada rol tiene su propio límite

3

Niveles de router

cheap, balanced y premium, con failover encadenado

ADOPCIÓN

Cómo se entra sin romper nada

Cuatro pasos, cada uno reversible y con su propio criterio de éxito.

01

Auditar

Revisar herramientas, skills y permisos ya instalados. El audit no garantiza ejecución, pero sí revela la superficie real.

02

Piloto

Un área, un proceso, un agente. Con presupuesto de tokens y traza activa desde el primer día.

03

Extender

Promover lo que funcionó a roles formalizados, con permisos y límites por rol.

04

Governar

Gates, respaldos, auditoría y actualización del stack incorporados a la rutina operativa.

GentleVanguard

El siguiente paso es un diagnóstico, no un contrato

Proponemos una sesión de trabajo para auditar cómo está hoy la IA en su organización y qué parte de esta plataforma se puede adoptar sin fricción. Sin costo y sin compromiso de implementación.

Solicitar el diagnóstico de stack

Ver la arquitectura completa

WhatsApp: +54 9 264 545-2221

Correo: gentlevanguard@gmail.com

Emmanuel Ortiz Gutierrez - Arquitecto de Software, Ingeniero de Integración de IA

El stack es open source. La adopción interna se hace sobre el repositorio y las políticas de la propia empresa.